머신러닝 단순교차검증

scikit-learn 의 train_test_split()함수를 사용하여
데이터를 훈련 세트와 테스트 세트로 한 번 나누는 것보다 더 성능이 좋은 평가방법은

교차검증
Cross-Validation

이다.

k-겹 교차검증에서
k 에는 5 or 10 과 같은 숫자가 들어가며,
데이터를 비슷한 크기의 집합 'k 개'로 나눈다. 이를 fold 라고 한다.

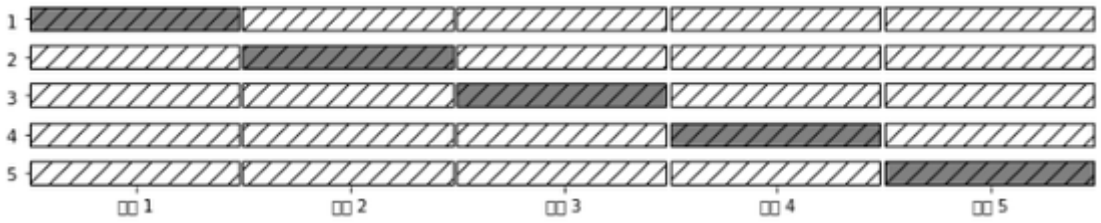

예를 들어, 5-겹 교차검증일 경우에는
데이터를 5 개로 분할한 다음 첫 번째 폴드를 테스트 데이터로 사용하고
나머지 2~5 폴드는 훈련용으로 사용하여 정확도를 평가한다.

그 다음, 두 번째 폴드를 테스트용으로 사용하고
1, 3~5 폴드를 훈련용으로 사용한다.

이런 식으로 폴드 1,2,3,4,5 를 각각 테스트용으로 사용하는데,
각각의 분할마다 정확도를 측정하고 이를 평균 내어 값을 구한다.

교차 검증을 위해 cross_val_score 함수를 불러오고,
사용할 데이터셋은 scikit-learn 의 유방암 데이터셋이다.

선형회귀와
KNN,
SVM,
의사결정트리,
랜덤포레스트 모델로
데이터를 학습시키고, 교차검증으로 정확도를 평가해보겠다.

```
# 교차 검증
from sklearn.model_selection import cross_val_score

# 유방암
from sklearn.datasets import load_breast_cancer

# 선형회귀
from sklearn.linear_model import LinearRegression

# KNN
from sklearn.neighbors import KNeighborsClassifier

# SVM
from sklearn.svm import LinearSVC

# 의사결정트리
from sklearn.tree import DecisionTreeClassifier

# 랜덤포레스트
from sklearn.ensemble import RandomForestClassifier
```

```
cancer = load_breast_cancer()
```

Variable explorer

Name	Type	Size	Value
cancer	utils.Bunch	6	Bunch object of sklearn.utils module

모델의 매개변수는 되도록이면 기본값인 상태로 진행한다.

각각의 모델들을 불러온 후, lr, knn, svm, tree, forest 에 저장한다.
매개변수는 되도록이면 기본값으로 설정.

선형회귀 학습모델

```
lr = LinearRegression()
```

IPython console

Console 1/A

```
In [81]: lr
Out[81]: LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None,
normalize=False)
```

KNN 학습모델

```
knn = KNeighborsClassifier(n_neighbors=4)
```

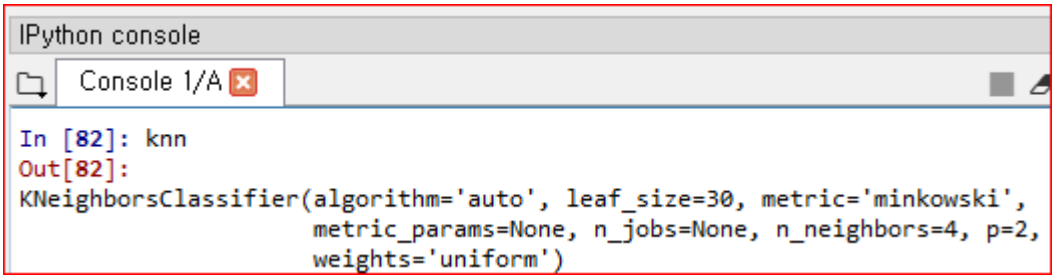

SVM 학습모델

```
svm = LinearSVC(random_state=0)
```

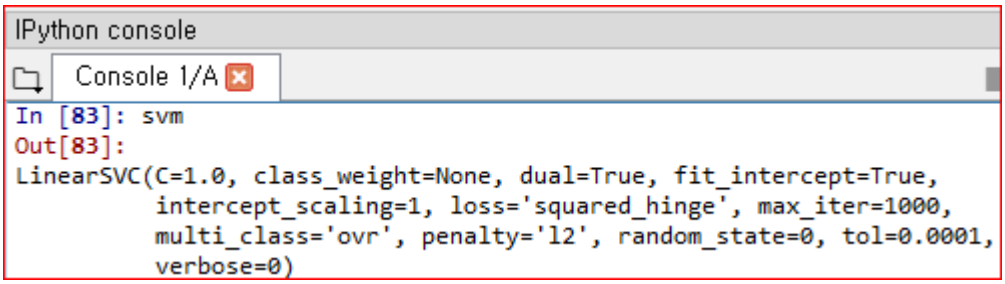

의사결정트리 학습모델

```
tree = DecisionTreeClassifier(max_depth=3,random_state=0)
```

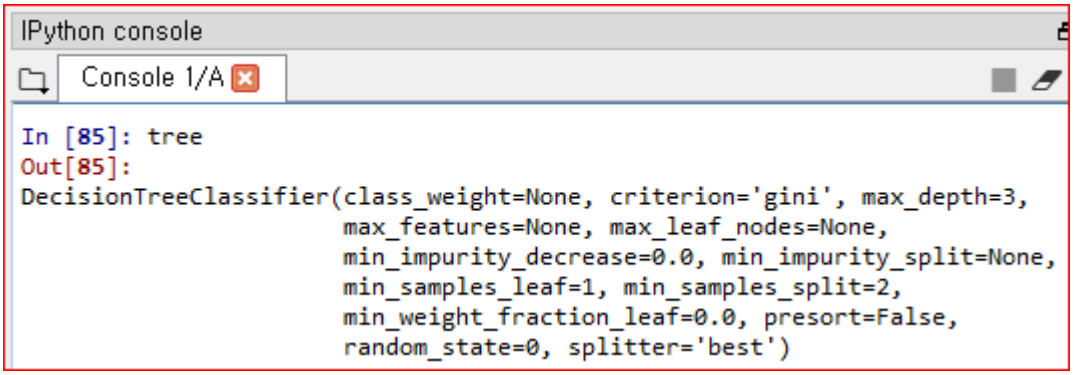

랜덤포레스트 학습모델

```
forest = RandomForestClassifier(n_estimators=6)
```

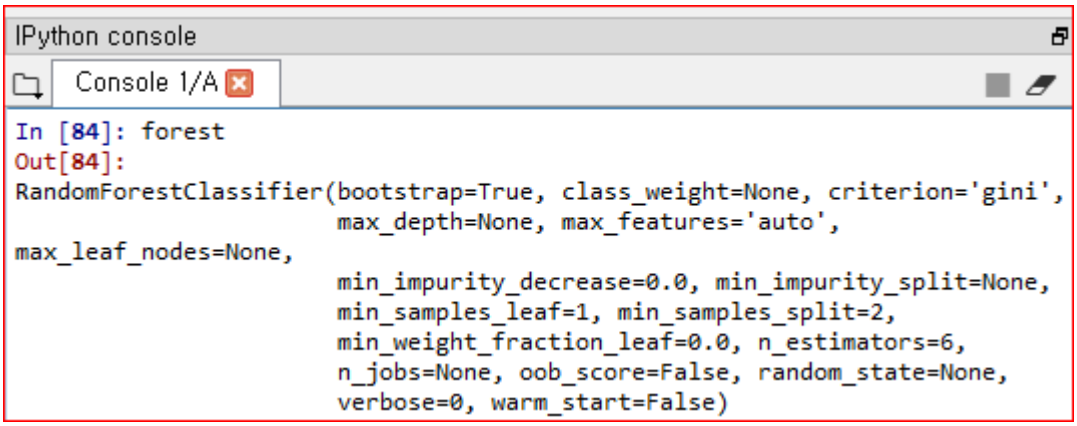

```
# 선형회귀 학습 후, 교차검증
score1 = cross_val_score(lr, cancer.data, cancer.target)

# KNN 학습 후, 교차검증
score2 = cross_val_score(knn, cancer.data, cancer.target)

# SVM 학습 후, 교차검증
score3 = cross_val_score(svm, cancer.data, cancer.target)

# 의사결정트리 학습 후, 교차검증
score4 = cross_val_score(tree, cancer.data, cancer.target)

# 랜덤포레스트 학습 후, 교차검증
score5 = cross_val_score(forest, cancer.data, cancer.target)
```

Variable explorer

Name	Type	Size	Value
cancer	utils.Bunch	6	Bunch object of sklearn.utils module
score1	float64	(3,)	[0.68274692 0.74112749 0.68552679]
score2	float64	(3,)	[0.90526316 0.95263158 0.9047619]
score3	float64	(3,)	[0.89473684 0.91578947 0.93121693]
score4	float64	(3,)	[0.9 0.95789474 0.89417989]
score5	float64	(3,)	[0.92105263 0.96842105 0.94179894]

교차 검증의 결과 확인

```
print('선형회귀 교차검증 점수 : {:.2f}'.format(score1.mean()))
print('KNN 교차검증 점수 : {:.2f}'.format(score2.mean()))
print('SVM 교차검증 점수 : {:.2f}'.format(score3.mean()))
print('의사결정트리 교차검증 점수 : {:.2f}'.format(score4.mean()))
print('랜덤포레스트 교차검증 점수 : {:.2f}'.format(score5.mean()))
```

IPython console

Console 1/A

```
In [91]: print('선형회귀 교차검증 점수 : {:.2f}'.format(score1.mean()))
선형회귀 교차검증 점수 : 0.70

In [92]: print('KNN 교차검증 점수 : {:.2f}'.format(score2.mean()))
KNN 교차검증 점수 : 0.92

In [93]: print('SVM 교차검증 점수 : {:.2f}'.format(score3.mean()))
SVM 교차검증 점수 : 0.91

In [94]: print('의사결정트리 교차검증 점수 : {:.2f}'.format(score4.mean()))
의사결정트리 교차검증 점수 : 0.92

In [95]: print('랜덤포레스트 교차검증 점수 : {:.2f}'.format(score5.mean()))
랜덤포레스트 교차검증 점수 : 0.94
```

Linear Regression 의 정확도는 70%,
KNN 은 92%,
SVM 은 91%,
DecisionTree 는 92%,
RandomForest 는 96%가 나왔다.

그렇다면, 다른 모든 조건을 그대로 유지하되
교차검증이 아닌 train_test_split()함수로 훈련셋과 테스트셋을 한 번만 나눠보겠다.

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, Y_train, Y_test = train_test_split(cancer.data,
                                                    cancer.target,
                                                    random_state=0)
```

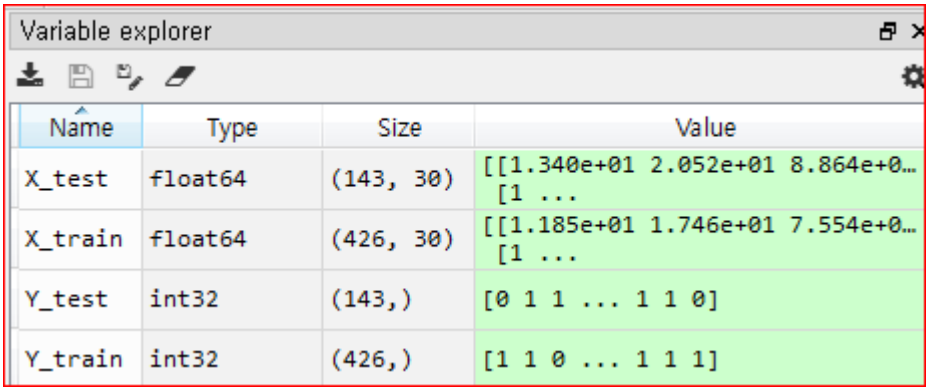


```
lr = LinearRegression().fit(X_train, Y_train)

knn = KNeighborsClassifier(n_neighbors=4).fit(X_train, Y_train)

svm = LinearSVC(random_state=0).fit(X_train, Y_train)

tree = DecisionTreeClassifier(max_depth=3,
                              random_state=0).fit(X_train, Y_train)

forest = RandomForestClassifier(n_estimators=6).fit(X_train, Y_train)
```

결과 확인

```
print('선형회귀 정확도 : {:.2f}'.format(lr.score(X_test, Y_test)))
print('KNN 정확도 : {:.2f}'.format(knn.score(X_test, Y_test)))
print('SVM 정확도 : {:.2f}'.format(svm.score(X_test, Y_test)))
print('의사결정트리 정확도 : {:.2f}'.format(tree.score(X_test, Y_test)))
print('랜덤포레스트 정확도 : {:.2f}'.format(forest.score(X_test, Y_test)))
```

성능이 좋아진 것도 있고 나빠진 것도 있다.

train_test_split 은 데이터를 무작위로 나누는데
이럴 경우 무작위로 나뉘어진 셋에
어떤 데이터들이 담기느냐에 따라서 정확도가 높고 낮아질 수 있다.

그러나, 교차검증은
각 폴드가 한 번씩 테스트 세트가 되므로
train_test_split 보다 데이터가 편향될 확률은 낮다